

Exercise 3.1, Binomial and multinomial models:

①
03

$\gamma = (\gamma_1, \dots, \gamma_J)$ följer en multinomial fördelning med parametrar $\theta = (\theta_1, \dots, \theta_J)$, vilket innebär att

$$p(\gamma|\theta) = \binom{n}{\gamma_1, \gamma_2, \dots, \gamma_J} \cdot \theta_1^{\gamma_1} \cdot \theta_2^{\gamma_2} \cdot \dots \cdot \theta_J^{\gamma_J} \propto \prod_{i=1}^J \theta_i^{\gamma_i}$$

Antag att $\theta = (\theta_1, \dots, \theta_J)$ följer en Dirichlet fördelning, så att priorfördelningen av θ med parametrar $a = (a_1, \dots, a_J)$ är

$$p(\theta) = \frac{\Gamma(a_1 + a_2 + \dots + a_J)}{\Gamma(a_1) \cdot \Gamma(a_2) \cdot \dots \cdot \Gamma(a_J)} \cdot \theta_1^{a_1-1} \cdot \theta_2^{a_2-1} \cdot \dots \cdot \theta_J^{a_J-1} \\ \propto \prod_{i=1}^J \theta_i^{a_i-1}$$

Detta ger posteriorfunktionen för θ som en Dirichlet fördelning med parametrar $(a_1 + \gamma_1, a_2 + \gamma_2, \dots, a_J + \gamma_J)$, ty

$$p(\theta|\gamma) \propto p(\theta) \cdot p(\gamma|\theta) \propto \prod_{i=1}^J \theta_i^{a_i-1} \cdot \prod_{i=1}^J \theta_i^{\gamma_i} \\ = \prod_{i=1}^J \theta_i^{(a_i + \gamma_i) - 1}$$

a) Bestäm marginella posteriorfunktionen för α , där

$$\alpha = \frac{\theta_1}{\theta_1 + \theta_2}$$

Exercise 3.1 forts.

②
03

α är en funktion av parametrarna θ_1 och θ_2 .

Därför kan vi först bestämma marginella posteriorfunktionen för $(\theta_1, \theta_2) | y$ och sedan med variabelbyte bestämma marginella posteriorfunktionen för $(\alpha, f(\theta_1, \theta_2))$, där funktionen f av parametrarna θ_1 och θ_2 väljs på ett lämpligt sätt.

Generellt, om $\theta = (\theta_1, \theta_2, \dots, \theta_j)$ följer en Dirichlet ford. med par. $(\alpha_1, \alpha_2, \dots, \alpha_j)$, så har vi ett resultat från appendix A, s. 582, att

$$(\theta_i, \theta_j, 1 - \theta_i - \theta_j) \sim \text{Dirichlet} \left(\alpha_i, \alpha_j, \sum_{k=1}^j \alpha_k - \alpha_i - \alpha_j \right),$$

d.v.s.

$$P[(\theta_1, \theta_2) | y] = \text{Dirichlet} \left(a_1 + y_1, a_2 + y_2, (a_3 + y_3) + \dots + (a_j + y_j) \right)$$

$$\propto \theta_1^{a_1 + y_1 - 1} \cdot \theta_2^{a_2 + y_2 - 1} \cdot (1 - \theta_1 - \theta_2)^{(a_3 + y_3) + \dots + (a_j + y_j) - 1}$$

Från denna marginella posteriorfunktion genomför vi nu ett variabelbyte från (θ_1, θ_2) till $\left(\alpha = \frac{\theta_1}{\theta_1 + \theta_2}, f(\theta_1, \theta_2) \right)$ och bestämmer den marginella täthetsfunktionen för $(\alpha, f(\theta_1, \theta_2))$.
Då har vi att

$$P[(\alpha, f(\theta_1, \theta_2)) | y] = P_{\theta_1, \theta_2} \left[\alpha(\theta_1, \theta_2), f(\theta_1, \theta_2) \right] \cdot \left| J[\alpha, f(\theta_1, \theta_2)] \right|$$

Exercise 3.1 forts.

(3)
03

där $|J(\alpha, f(\theta_1, \theta_2))|$ är areaförändringen under variabelbytet och definieras som

$$J(\alpha, f) = \frac{d(\theta_1, \theta_2)}{d(\alpha, f)} = \frac{1}{\frac{d(\alpha, f)}{d(\theta_1, \theta_2)}} = \frac{1}{\begin{vmatrix} \frac{d\alpha}{d\theta_1} & \frac{d\alpha}{d\theta_2} \\ \frac{df}{d\theta_1} & \frac{df}{d\theta_2} \end{vmatrix}}$$

Vi har att $\alpha = \frac{\theta_1}{\theta_1 + \theta_2}$, men hur ska vi välja $f(\theta_1, \theta_2)$ på ett lämpligt sätt? Om vi väljer f så att α och f är oberoende av varandra ges den marginella täthetsfunktionen för α direkt, ty då gäller det att den simultana täthetsfunktionen för α, f är

$$p[(\alpha, f) | y] = p(\alpha | y) \cdot p(f | y).$$

Notera att den marginella posteriorfunktionen för $(\theta_1, \theta_2) | y$ innehåller termerna $\theta_1, \theta_2, \theta_1 + \theta_2$, som ska ersättas med parametrarna α och $f(\theta_1, \theta_2)$. Vi har att

$$\alpha = \frac{\theta_1}{\theta_1 + \theta_2} \Rightarrow \theta_1 = \alpha \cdot (\theta_1 + \theta_2), \text{ vilket ger direkt från } p[(\theta_1, \theta_2) | y] \text{ att } f \text{ definieras som } f(\theta_1, \theta_2) = (\theta_1 + \theta_2)$$

medför en "uppdelning" av termerna α och f vid substitution (4)
 av $\theta_1 = \alpha \cdot f$, $\theta_1 + \theta_2 = f$, eftersom 03

$$\theta_1^{a_1+y_1-1} = \alpha^{a_1+y_1-1} \cdot f^{a_1+y_1-1}(\theta_1, \theta_2), \text{ och}$$

$$(1 - \theta_1 - \theta_2)^{(a_3+y_3)+\dots+(a_J+y_J)-1} = (1 - f(\theta_1, \theta_2))^{(a_3+y_3)+\dots+(a_J+y_J)-1}.$$

Den kvarvarande termen, θ_2 , från $p[(\theta_1, \theta_2)|y]$ ger också denna "uppdelning", ty $\theta_2 = f - \alpha \cdot f = f \cdot (1 - \alpha)$, så att

$$\theta_2^{a_2+y_2-1} = (f \cdot (1 - \alpha))^{a_2+y_2-1} = f^{a_2+y_2-1} \cdot (1 - \alpha)^{a_2+y_2-1}.$$

Med $f(\theta_1, \theta_2) = \theta_1 + \theta_2$ beräknar vi till sist $J(\alpha, f)$. Vi har att

$$\frac{d\alpha}{d\theta_1} = \frac{\theta_2}{(\theta_1 + \theta_2)^2}, \quad \frac{d\alpha}{d\theta_2} = -\frac{\theta_1}{(\theta_1 + \theta_2)^2}$$

$$\frac{df}{d\theta_1} = 1, \quad \frac{df}{d\theta_2} = 1, \quad \text{så att}$$

$$J(\alpha, f) = \frac{1}{\begin{vmatrix} \frac{\theta_2}{(\theta_1 + \theta_2)^2} & -\frac{\theta_1}{(\theta_1 + \theta_2)^2} \\ 1 & 1 \end{vmatrix}} = \frac{1}{\frac{\theta_2}{(\theta_1 + \theta_2)^2} - \left(-\frac{\theta_1}{(\theta_1 + \theta_2)^2}\right)} = \frac{1}{\frac{1}{\theta_1 + \theta_2}}$$

$= \theta_1 + \theta_2 = f(\theta_1, \theta_2)$. Detta ger den simultana täthetsfunktionen för α och f som

$$p[\alpha, f(\theta_1, \theta_2)|y] = \alpha^{a_1+y_1-1} \cdot f^{a_1+y_1-1}(\theta_1, \theta_2) \cdot f^{a_2+y_2-1}(\theta_1, \theta_2) \cdot (1 - \alpha)^{a_2+y_2-1}.$$

$$\cdot (1 - f(\theta_1, \theta_2))^{(a_3 + y_3) + \dots + (a_J + y_J)} - 1$$

=

(5)
03

$$= \underbrace{\alpha^{a_1 + y_1 - 1} \cdot (1 - \alpha)^{a_2 + y_2 - 1}}_{= p(\alpha | y)} \cdot p[f(\theta_1, \theta_2) | y]$$

Alltså, $\alpha | y \sim \text{Beta}(a_1 + y_1, a_2 + y_2)$.

Exercise 3.1 b

$$Y_1 \sim \text{Bin}(n = y_1 + y_2, \alpha) \Rightarrow p(y_1 | \alpha) \propto \alpha^{y_1} \cdot (1 - \alpha)^{y_1 + y_2 - y_1} = \alpha^{y_1} \cdot (1 - \alpha)^{y_2}$$

Visa att

$$\alpha | y_1 \sim \text{Beta}(a_1 + y_1, a_2 + y_2), \text{ d.v.s. samma förd. som i a.}$$

Vi har att

$$p(\alpha | y_1) \propto p(\alpha) \cdot p(y_1 | \alpha) \propto p(\alpha) \cdot \alpha^{y_1} \cdot (1 - \alpha)^{y_2}$$

Välj prior $p(\alpha)$ som $\alpha \sim \text{Beta}(a_1, a_2)$, vilket ger

$$p(\alpha | y_1) \propto \alpha^{a_1 - 1} \cdot (1 - \alpha)^{a_2 - 1} \cdot \alpha^{y_1} \cdot (1 - \alpha)^{y_2}$$

$$= \alpha^{a_1 + y_1 - 1} \cdot (1 - \alpha)^{a_2 + y_2 - 1}, \text{ vilket skulle visas.}$$

Binomialfördelningen för y_1 är ett specialfall av multinomialfördelningen.

Den Beta-fördelade prior är ett specialfall av Dirichlets fördelning.

Specialfall med tanke på att endast två utfall. Alltså visar detta att om man utgår ifrån ett generellt andel utfall J stycken och ignorerar informationen från övriga utfall utom två stycken erhåller man samma resultat som ignorering av det övriga data med undantag y_3, \dots, y_J från borgen.

Exercise 3.2 forts.

7
03

Ansätt en Dirichlet fördelning som konjugerad priorfördelning med parametrar $(a_{1,f}, a_{2,f}, a_{3,f})$. Då ges posteriorfördelningen

$$\theta_f | y_f \text{ som } p(\theta_f | y_f) \propto \prod_{i=1}^3 \theta_{i,f}^{a_{i,f} + y_{i,f} - 1}.$$

Antag att vi inte känner till någonting om rösterbäddigades preferenser inför undersökningarna. Då är det naturligt att ansätta en icke-informativ priorfördelning för $\theta_{i,f}$.

$$\text{t.ex. } a_{i,f} = 1, \quad i = 1, 2, 3$$

Det ger $p(\theta_f | y_f) \propto \prod_{i=1}^3 \theta_{i,f}^{y_{i,f}}$ så att

$$\begin{aligned} \theta_f | y_f &\sim \text{Dirichlet}(y_{1,f} + 1, y_{2,f} + 1, y_{3,f} + 1) = \\ &= \text{Dirichlet}(295, 308, 39). \end{aligned}$$

Vi söker dock posteriorfördelningen för $\alpha_f = \frac{\theta_{1,f}}{\theta_{1,f} + \theta_{2,f}}$,

d.v.s. andelen Bushpreferenser av Bush och Dukakispreferenserna sammantagna andel.

Den får vi genom att utnyttja resultatet från exercise 3.1a. Vi har då att

$$\begin{aligned} \alpha_f | y &\sim \text{Beta}(a_1 + y_{1,f}, a_2 + y_{2,f}) = \text{Beta}(y_{1,f} + 1, y_{2,f} + 1) \\ &= \text{Beta}(295, 308). \end{aligned}$$

Exercise 3.2 fords.

8
03

P.s.s. för vi


$$\alpha_e | y \sim \text{Beta}(289, 333) .$$

Nu söker vi posteriofordelningen för det "shift",
 $\alpha_e | y - \alpha_f | y$ som uppstod av debatteffekten.

Slumpa därför 1000 värden från respektive Beta-fordelning
 $\theta_e | y$ och $\theta_f | y$, bilda differensen $\theta_{e,i} - \theta_{f,i}$ för
varje slumpmässigt värde där $i = 1, 2, \dots, 1000$
och plotta differenserna i ett histogram, se figur 3.1

Från histogrammet kan vi utläsa posteriorsannolikheten, att
debatten ledde till ett shift mot Bush, som arean under
posteriofordelningen till höger om 0.

figure 3.1



Exercise 3.5, Rounded data

9

03

Ett objekt vägs 5 gånger och de olika viktarna avrundas till närmaste pound. Sätt $y_{\text{round}} = y$

och $y_{\text{exakt}} = x$. Vi har från uppgiften att

$$y = (y_1, y_2, \dots, y_5) = (10, 10, 12, 11, 9)$$

och vi antar att

$$x_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$$

med en icke-informativ prior fördelning för (μ, σ^2) (gavs i kap. 2)

som $p(\mu, \sigma^2) \propto \sigma^{-2}$

a) Posteriorfördelningen för (μ, σ^2) ges uttryckligen i kap. 2 om man behandlar de avrundade observationerna som exakta, d.v.s. $(y_1, \dots, y_5) = (x_1, \dots, x_5)$, se sid. 74, 75.

Det gäller att den betingade posteriorfördelningen för μ och den marginella posteriorfördelningen för σ^2 , ges som

$$\mu | \sigma^2, y \sim N(\bar{y}, \sigma^2/n) = N(10.4, \sigma^2/5)$$

$$\sigma^2 | y \sim \text{Inv-}\chi^2(n-1, s^2) = \text{Inv-}\chi^2(4, 1.3)$$

dar vi får från $y = (y_1, \dots, y_5)$ att $n=5$, $\bar{y}=10.4$, $s^2=1.3$

Exercise 3.5 forts.

10

03

b) Om däremot observationerna $y = (y_1, \dots, y_5)$ behandlas
korekt som avrundade värden ges posteriorfunktionen för (μ, σ^2)

som

$$p(\mu, \sigma^2 | y) \propto p(\mu, \sigma^2) \cdot p(y | \mu, \sigma^2)$$

Observera att vi endast känner till fördelningen för de exakta värdena
 (x_1, \dots, x_5) , men täthetsfunktionen $p(y | \mu, \sigma^2)$ inkluderar "alla"
täthetsfunktioner för x på intervallet $[y - \frac{1}{2}, y + \frac{1}{2}]$, eftersom

$y_i = 10 \Rightarrow 9,5 < x < 10,5$. Därför bestämmer vi den
summande täthetsfunktionen på varje intervall genom att integrera
täthetsfunktionen för varje icke avrundad observation x_i över
intervallet. Vi kan därför skriva

$$p(\mu, \sigma^2 | y) \propto \sigma^{-2} \cdot \prod_{i=1}^5 p(y_i | \mu, \sigma^2) = \sigma^{-2} \cdot \prod_{i=1}^5 \left[\int_{y_i - \frac{1}{2}}^{y_i + \frac{1}{2}} p(x_i | \mu, \sigma^2) dx_i \right]$$

$$= \sigma^{-2} \cdot \prod_{i=1}^5 \left[P\left(y_i - \frac{1}{2} < x_i \leq y_i + \frac{1}{2}\right) \right] = \sigma^{-2} \cdot$$

$$\prod_{i=1}^5 \left[P\left(\frac{y_i - \frac{1}{2} - \mu}{\sigma} < \frac{x_i - \mu}{\sigma} \leq \frac{y_i + \frac{1}{2} - \mu}{\sigma}\right) \right] =$$

$$= \sigma^{-2} \cdot \prod_{i=1}^5 \left[\Phi\left(\frac{y_i + \frac{1}{2} - \mu}{\sigma}\right) - \Phi\left(\frac{y_i - \frac{1}{2} - \mu}{\sigma}\right) \right]$$

Exercise 3.5, forts.

(11)
53

c) Simulerar 1000 värden från respektive posteriorfördelning i a) och b).

Posteriorfördelningen från a) är lätt att simulera ifrån. Vi har kända fördelningen att simulera ifrån för den betingade täthetsfunktionen över μ och marginella täthetsfunktionen över σ^2 .

Drag först ett slumpmässigt värde $\sigma_{(i)}^2$ från den inversa- χ^2 ford. $\chi^2(4, 1.3)$ och använd sedan detta värde för att dra ett värde $\mu_{(i)}$ från $N(10.4, \sigma_{(i)}^2/5)$. X dras först från $\chi^2(4)$ och sedan beräknas $\sigma_{(i)}^2 = \frac{4 \cdot 1.3}{X}$.

Posteriorfördelningen från b) är inte känd och kan inte delas upp i några "komponenter" som i a). Bestäm därför först

$p(\sigma^2|y)$ genom att approximerar denna marginella

täthetsfunktion som $p(\sigma^2|y) \approx \sum_{\beta} p(\sigma^2|y, \beta)$.

Beräkna den kumulativa fördelningen,

$\sum_{\sigma^2} p(\sigma^2|y)$ för respektive värde σ^2 .

Normalisera den kumulativa fördelningen som

$$p_N(\sigma^2|y) = \frac{p(\sigma^2|y)}{p_{\max}(\sigma^2|y)}$$

. Slumpa sedan fram

ett värde u från $U[0,1]$ och finn det värde σ^2 där $u = p_N(\sigma^2|y)$.

Exercise 3.5 forts.

12

03

På liknande sätt kan man simulera från värden $y_{(i)}$ genom att approximera den betingade täthetsfunktionen $p(\mu | \sigma^2, y)$ givet värden $\sigma_{(i)}^2$.

Tabell 3.1 ger skillnaden mellan posteriorfördelningarna och **figur 3.2** och **3.3** åskådliggör contour-plottarna för respektive posteriorfördelning.

d) Drag simuleringar från posteriorfördelningen av x .
Vi har att

$$x_i \stackrel{iid}{\sim} N(\mu, \sigma) \quad ; \quad -\infty < x_i < \infty$$

Givet observation y_i , vet vi att $y_i - \frac{1}{2} < x_i < y_i + \frac{1}{2}$.

Det ger att $x_i | \mu, \sigma^2, y_i$ är en trunkerad normalfördelning på intervallet ovan. Alltså,

$$x_i | \mu, \sigma^2, y_i \sim N(\mu, \sigma^2) \quad ; \quad y_i - \frac{1}{2} < x_i < y_i + \frac{1}{2}.$$

På liknande sätt som tidigare kan vi approximera och normalisera fördelningsfunktionen för varje $N(\mu_{(i)}, \sigma_{(i)}^2)$ och sedan bestämma det korresponderande värdet $x_{(i)}$ där den trunkerade fördelningsfunkt. för $N(\mu_{(i)}, \sigma_{(i)}^2)$ är lika med ett slumpmässigt värde u från $U[0,1]$.

Övning 3.12, Poisson regression model

13

03

Betrakta övning 2.13 a)

I tabell 2.2 ges ant. livshotande olyckor för schemalagda flygningar per år mellan åren 1976-1985

Låt y_i = ant. livshotande olyckor för år i ; $i = 1, 2, \dots, 10$

$y_i \sim \text{Poisson}(\theta = \alpha + \beta \cdot i)$, tid. $y_i \stackrel{\text{iid.}}{\sim} \text{Poisson}(\theta)$

$$\Rightarrow P(y_i | \theta = \alpha + \beta \cdot i) = \frac{1}{y_i!} \cdot (\alpha + \beta \cdot i)^{y_i} \cdot \exp(-(\alpha + \beta \cdot i))$$

Vi vill dock försäkra oss om att $\theta > 0$, så att

låt istället $\log \theta = \alpha + \beta \cdot i \Rightarrow \theta = \exp(\alpha + \beta \cdot i)$

och
$$P(y_i | \theta = \exp(\alpha + \beta \cdot i)) = \frac{1}{y_i!} \cdot (\exp(\alpha + \beta \cdot i))^{y_i} \cdot \exp(-\exp(\alpha + \beta \cdot i))$$

a) Välj $P(\alpha, \beta) \propto 1$ som icke-informativ priorfördelning.

En annan icke-informativ priorfördelning för (α, β) skulle kunna väljas som en bivanst normalfördelning med

höga varianser σ_α^2 och σ_β^2 för att skapa en så pass flach priorfördelning att man kan använda den som en icke-informativ priorfördelning.

Exercise 3.12 forts.

(14)

03

b)

En realistisk informativ prior-fördelning för (α, β) kan vara att utgå ifrån y_0 , d.v.s. antalet livshodmole flygolyckor är 1975 och uppskatta förändringen av antalet olyckor med tidigare data eller erfarenhet. En bivarierad normalfördelning, centrerad kring $E[\alpha] \approx \log(y_0)$ och $E[\beta] \approx \hat{\Delta} y_i$, med kovariansmatris

dar y_0 mäts
i hundratal

$$V_{ij} = \begin{bmatrix} \sigma_\alpha^2 & \rho \cdot \sigma_\alpha \cdot \sigma_\beta \\ \rho \cdot \sigma_\alpha \cdot \sigma_\beta & \sigma_\beta^2 \end{bmatrix}.$$

Exempelvis $\mu_\alpha = -1.6$, $\mu_\beta = 0$

$$V_{ij} = \begin{bmatrix} 0.4 & 0.3 \\ 0.3 & 0.25 \end{bmatrix}$$

En contour plot av denna bivarierade normalfördelning ges i figur 3.4.


c) Vi har att $p(\alpha, \beta) \propto 1$. Alltså blir posteriorfunktionen för (α, β) proportionell mot Likelihoodfunktionen

$y = (y_1, y_2, \dots, y_{10}) \mid \alpha, \beta$, så att

$$p(\alpha, \beta \mid y, t) \propto \prod_{i=1}^{10} p(y_i \mid \theta = e^{\alpha + \beta \cdot i})$$

$$\propto \prod_{i=1}^{10} \left(\exp(\alpha + \beta \cdot i) \right)^{y_i} \cdot \exp \left(- \exp(\alpha + \beta \cdot i) \right) =$$

Figur 3.4: Contour plot för (α, β) med en informativ bivariat normalfördelning som prior



Exercise 3.12 forts.

15

03

c) forts.

$$= e^{\alpha \cdot \sum_{i=1}^{10} y_i} \cdot e^{\beta \cdot \sum_{i=1}^{10} i \cdot y_i} \cdot \prod_{i=1}^{10} \exp\left(-\exp(\alpha + \beta \cdot i)\right),$$

vilket ger de tillräckliga statistikerna som

$$\sum_{i=1}^{10} y_i \quad \text{och} \quad \sum_{i=1}^{10} i \cdot y_i$$

d) Posteriorfunktionen är proper, ty den består av en produkt av Poisson-sannolikheter, vilket innebär att

$$p(\alpha, \beta | y, t) < 1 < \infty, \quad \text{och}$$

då $(\alpha, \beta) \rightarrow \pm \infty$ går $p(\alpha, \beta | y, t)$ mot noll.

Detta ger att $\iint_{-\infty}^{\infty} p(\alpha, \beta | y, t) d\alpha d\beta < \infty$

Alltså ges arean under posteriorfunktionsen av ett positivt ändligt tal och det innebär att posteriorfunktionsen är proper.

Exercise 3.12 forts.

16
03

e) Vi har att

$$\log \theta = \alpha + \beta \cdot t,$$

så att vi kan erhålla en approximativ skattning $(\hat{\alpha}, \hat{\beta})$ genom linjär regression av $\log(y_i)$ på tidspunkterna t_i för de 10 olika åren, där $t_1=1, \dots, t_{10}=10$.

Datanoden ges från tabell 2.2 och regressionsresultatet blev

	skattning	st. avv. skattning
α	-1,231	0,1153
β	-0,040	0,0186

y_i mäts i hundratal

f) Tabellen i uppg. e, ger oss ledtrådar för vilka värden på (α, β) vi ska skapa en contour plot utifrån, se figur 3.5

$$\sum_{i=1}^{10} y_i = 2438, \quad \sum_{i=1}^{10} i \cdot y_i = 12433. \quad \text{Alltså har vi}$$

$$p(\alpha, \beta | y, t) \propto e^{2438 \cdot \alpha + 12433 \cdot \beta} \cdot \prod_{i=1}^{10} \exp(-\exp(\alpha + \beta \cdot i))$$

1000 slumpmässiga dragningar från posteriorfunktionen bestäms enligt följande: Approximera den marginella täthetsfunktionen av α som

$$p(\alpha | y, t) \approx \sum_{\beta} p(\alpha, \beta | y, t), \quad \text{d.v.s. summera ut } \beta \text{ för resp. } \alpha$$

Bestäm den kumulativa fördelningsfunktionen för varje α , i.e. (17)

03

$P_k(\alpha_{(i)} | y, t) \approx \sum_{\alpha=\alpha_{\min}}^{\alpha_{(i)}} P(\alpha | y, t)$ och tag fram den
normerade kumulativa fördelningsfunktionen som

$$P_{kN}(\alpha_{(i)} | y, t) = \frac{P_k(\alpha_{(i)} | y, t)}{P_k(\alpha_{\max} | y, t)}$$

definierad på intervallet $[0,1]$.

Nu utnyttjar vi den inversa fördelningsfunktion metoden, så slumpa fram ett värde u från $U[0,1]$ och finn det värde $\alpha_{(i)}$ som uppfyller likheten

$$u = P_{kN}(\alpha_{(i)} | y, t), \text{ vilket är det slumpade värdet för } \alpha.$$


Utnyttja det slumpade värdet $\alpha_{(i)}$ för att bestämma den
bedingade posteriorfunktionen

$P(\beta_{(i)} | y, t, \alpha_{(i)})$ och den kumulativa fördelningsfunktionen
för varje β . Fortsätt sedan p.s.s. som ovan, givet $\alpha_{(i)}$,
för att slumpa fram värdet $\beta_{(i)}$.

Denna procedur upprepas 1000 gånger vilket gav

$$(\alpha_{(i)}, \beta_{(i)}) \text{ för } i = 1, 2, \dots, 1000.$$

Figur 3.5: Contour plot av posteriorfunktion för (α, β) med en icke-informativ prior



Exercise 3.12 forts.

(18)

03

g) Ett histogram för posteriorfördelningen av
 $\theta = E[Y_i | t = 1986] = e^{\alpha + \beta \cdot 11}$

plottas utifrån de slumpade värdena $(\alpha_{(i)}, \beta_{(i)})$, $i = 1, 2, \dots, 1000$
så att värdena

$$\theta_{(i), 1986} = e^{\alpha_{(i)} + \beta_{(i)} \cdot 11} \quad \text{för } i = 1, 2, \dots, 1000$$

används för att plotta histogrammet, se figur 3.6

h) Ett 95% - igt prediktionsintervall för Y_{1986} ges
från värdena $\theta_{(i), 1986}$, $i = 1, 2, \dots, 1000$, där varje

$\tilde{Y}_{(i), 1986}$ slumpas fram från en Poissonfördelning med
väntevärde $\theta_{(i), 1986}$, ty vi har att

$\tilde{Y}_{1986, i} \sim \text{Po}(\theta_i)$, där y_i är oberoende observationer för
respektive i . Ordna sedan de prediktade värdena
 $\tilde{Y}_{(i), 1986}$ i storleksordning och skatta den undre och övre
intervallgränsen som $\hat{\pi}_{0,025} = \tilde{Y}_{(i), (25)}$ och $\hat{\pi}_{0,975} = \tilde{Y}_{(i), (975)}$
där $\hat{\pi}_p = \tilde{Y}_{(i), (1000 \cdot p)}$ är den skattade $p\%$ - percentilen
för den $(1000 \cdot p)$:e största observationen.

Exercise 3.12 forts.

19

03

b)

Om man jämför contour plots mellan
figur 3.4: Contour plot för (α, β) vid användning av
den informativa priorfördelningen och

figur 3.5: Contour plot för posteriorfördelning av (α, β)
vid användning av en icke-informativ priorfördelning
kan man tydligt urskilja att fördelningen för (α, β) i figur 3.4
är mer koncentrerad ^{för α} än i figur 3.5, vilket kan förklaras
av att den icke-informativa prior är tillräckligt dominerande
för att posteriorfördelningen av (α, β) innehåller en hög variation,
vilket innebär att det lilla determinantalet för y_i inte verkar
ha fått den effekt för att justera den icke-informativa prior.

Notera dock att för β är istället posteriorfunktionen för (α, β)
mer koncentrerad än fördelningen för den informativa priorfördelningen
för (α, β) , men om den informativa prior istället hade använts,
skulle förmodligen posteriorfunktionen vara mer koncentrerad än den med
icke-informativ prior.